

AI 时代经济学研究工具与方法

2026 年暑期课程期末作业纸质提交材料

项目	内容
姓名	邓鸿琪
学号	825200520
学院及专业	江西财经大学数字经济学院 2025 级产业经济学硕士研究生
GitHub 仓库	待本人创建仓库后填写
提交日期	2026-09-04
用 AI 完成的工作	复现 DID，完成 11 项必做及 1 项扩展检验；设计 Skill 与评估 Agent；以两轮对照和错误输入测试完善验证，并形成可编译论文。

主要发现：基准系数 0.120920；短窗口与聚类推断存在敏感性，管理能力互补性未获支持。全部数据为合成教学数据，不构成真实企业因果证据。

一、识别目标

项目	我的回答
处理与对照	151 家企业于 2020 年采用数字化，209 家从未采用；面板共 360 家、3240 个观测。
处理时间	2016—2024 年观察，2020 年同步处理；不存在交错采用。
目标估计量	处理组 2020—2024 年平均 ATT。基准系数仅在识别假设成立时与该目标对应；改变时间窗口会改变平均对象。
关键假设	条件平行趋势、无预期、无溢出、处理定义一致、样本构成稳定；控制项不为处理后中介。
主要威胁	采用自选择、企业时变混杂、小簇推断、能力测量误差。DGP 含每年 0.0008 额外趋势，预趋势不显著不能证明假设成立。

本材料由 Codex 辅助分析与草拟，记录以实际文件和执行证据为准；署名研究者提交前复核。

二、我设计的 Prompt

示例 A R2 随机伪处理组安慰剂

【目标】读取 data/raw/digital_transformation_firm_panel.csv。企业层面固定真实处理组数量，处理时点保持 2020；固定种子 825200520，重复 300 次，保留全时间序列，在每次回归中使用相同 FE 和控制集。

【边界】仅为合成数据教学演示，不解释为真实企业因果证据；data/只读，变换在内存完成；不虚构文献，不选择性隐藏结果；发现不能识别或必要输入缺失先停止并说明。

【验证】保存每次系数、SE、p、N 与失败；报告均值、分位数和双侧尾部计数。随机分配不符合真实采用机制，不能解释为精确随机化因果检验。初版先报告直接尾部比例，后续审查其有限模拟解释。每项同时核验个体×时间唯一、样本构成、处理变化和原数据 SHA256 不变。

【汇报】报告估计值、聚类标准误、参考自由度、p 值、样本量、企业数及本项特定诊断；输出 CSV 与必要图形，说明符合/不符合预期及下一步。统计显著性不能取代识别论证。

设计理由：固定分配单位、种子和样本，保留全部重复，使后续 Skill 对照可比较。

示例 B T3 能力互补性

【目标】读取 data/raw/digital_transformation_firm_panel.csv。能力使用处理前均值并按企业样本中心化，加入 digital 及 digital×中心化能力，企业/年份 FE、企业聚类。

【边界】仅为合成数据教学演示，不解释为真实企业因果证据；data/只读，变换在内存完成；不虚构文献，不选择性隐藏结果；发现不能识别或必要输入缺失先停止并说明。

【验证】报告交互项及其区间；能力主项被 FE 吸收。区分收益异质性相关、机制因果识别和 DGP 设定；不得引入 Matlab。每项同时核验个体×时间唯一、样本构成、处理变化和原数据 SHA256 不变。

【汇报】报告估计值、聚类标准误、参考自由度、p 值、样本量、企业数及本项特定诊断；输出 CSV 与必要图形，说明符合/不符合预期及下一步。统计显著性不能取代识别论证。

设计理由：在运行前规定处理前能力和中心化，并明确交互显著也不等于机制因果识别。

Prompt 设计心得

最容易跑偏的是把“检验不显著”解释为“假设成立”。R1 要求联合检验及区间，R5 要求簇数和二维定义，T3 要求不显著也如实写出。共用四要素只统一结构，各检验的验证项围绕不同识别威胁设计。R2 初版的直接尾部率 0 在第一轮修订中增加了有限模拟限定，未据此改动回归结果。

三、我设计的 Skill

3.1 六模块摘要

模块	设计要点
触发条件	面板 DID 复现与稳健性诊断；不替代其他识别方法。
背景知识	先区分 ATT、处理暴露、处理组、时点、FE 和聚类；记录估计量与假设。
工作步骤	读取说明和数据→确认变量语义→生成外部契约→校验时序→复现基线→逐项运行→保存证据。
检查清单	唯一键、缺失、处理反转、同步采用、平衡面板、吸收项、处理前分组、少簇、全量重复。
边界条件	数据只读，缺失语义先询问；模拟不解释为现实因果证据；交错采用转用合适估计器。
验证方式	独立实现对照、哈希、全量随机结果、同种子重跑；计数和有限模拟分辨率同时报告。

3.2 Skill 与裸 Prompt 对比

维度	裸 Prompt／原型	修订 Skill
检验	R2: 300 次、种子 825200520	相同数据、模型、分配规则和种子
数值	0 次超越，直接比例 0/300	仍为 0 次；300 个系数最大差 0
解释	没有量化模拟分辨率，易被误读成 $p=0$	加一平滑 $1/301=0.003322$ ；单侧 95%上界 0.009936；限定为模拟诊断
可审计性	保留回归及种子	增加契约、吸收项、前后哈希和完整状态

差异的本质：把需重复提醒的验证条件写入程序和制度，不以更显著的数字证明 Skill 有效。裸 Prompt 已有完整随机分布，不虚构“原版什么都没有”的对照。

3.3 一般适用性自检

迁移到重新生成的最低工资与就业合成面板时，重新确定地区、年份、对数就业、政策暴露及外生控制，改变采用时点和收益方向；Skill 源码不改。80 地区、8 年、120 次模拟完成；重复键、处理反转与交错采用均触发停止。通用的是检查制度，同步平衡面板辅助程序有明确适用范围，不能推广为任意 DID 都可自动运行。

四、我设计的 Agent

4.1 结构摘要

要素	我的设计
名称	eval-did-robustness
目标	把主回归与全部诊断转化为有证据、有限定的综合判断。
输入	识别目标、变量映射、主结果与参考实现、各项 CSV、事件结果、安慰剂重复、诊断和汇总。
S1—S2	读取证据并核对口径；按通过、警示、失败逐项判定。通过只表示局部诊断未发现预定问题。
S3—S4	分别评价方向、量级、精度及估计对象；列出趋势、溢出、测量、采用选择、小簇和外部效度威胁。
S5—S6	解释能力互补性与异质性，再列可以写、须限定后写、不能写的具体语句。
输出	主结果、判定表、稳定性、残余威胁、主题解读、写作建议、边界声明及证据来源。
边界	工具仅 Read/Glob/Grep；不跑回归、不改论文。调用者保存报告并验证受保护文件哈希。
验证	先校验必备文件、规格覆盖、数字范围和跨 CSV 一致性；在临时副本进行错误输入测试。

4.2 设计心得

最容易遗漏的是：Agent 说明写了“缺失就停”，配套程序却未实际检查。初版报告已经包含主题解释，但输入门槛不足。第二轮不是重写一遍结论，而是用缺失与篡改样例验证停止行为，再修复缺口。

评估最有价值的部分是把三种现象分开：R5 仍显著但精度不稳定；R7 下降涉及动态平均对象改变；T3 未获支持属于研究假说证据不足，不是程序失败。这些区别直接约束论文措辞。

实现说明：本次由 Codex 按照 Agent 文件完成语义评估，evaluate.py 进行确定性校验和装配；未声称调用独立外部模型。通用 Agent 说明与课程项目适配脚本分开，迁移时需重新配置输入及主题内容。

五、迭代反思

第一轮 Skill 的有限模拟解释

观察问题：R2 裸 Prompt 与 Skill 原型都得到 `tail_count=0`、`tail_rate=0`。零次超越是计数事实，但不能推出尾部概率为零。原型虽保留全量抽样，未量化有限重复的不确定性。

修订：在 Skill 验证清单与辅助程序加入加一平滑比例、模拟分辨率、零超越上界、失败重复状态和原数据哈希。固定数据、种子与模型重跑，避免把结果差异误当设计改进。

修订前输出：`tail_count: 0; tail_rate: 0.0`。

修订后输出：`smoothed_tail_rate: 0.003322259; tail_probability_upper95: 0.009936082; status: complete`。300 个系数最大绝对差为 0。

证据：4e57924（原型）→819ad98（修订）；`output/iterations/skill_v1`、`output/skill_r2`、`output/skill_comparison.json`。

第二轮 Agent 的输入验证

观察问题：在临时副本删除事件文件、改基准、删短窗口规格、令 $p=1.2$ ，初版校验仍接受；只有重复行被识别。六例含一个正常样本，初版仅 2/6 符合预期。这里没有捏造 AI 先前说过的话，证据是实际程序行为。

修订：增加必备输入与规格契约、有限数与概率范围、分项结果交叉核对、安慰剂重复校验及哈希检查。正常输入继续接受，五类错误全部停止。

修订前输出：`missing_event_file → accepted: true; changed_baseline → accepted: true`。

修订后输出：`missing_event_file → STOP: missing required evidence; changed_baseline → STOP: source mismatch baseline`。6/6 符合预期。

证据：8b216e6（初版）→9049b5c（修订）；`output/iterations/agent_v1_tests.json`、`agent_v2_tests.json`。

迭代总结

需要改变的不是让 AI 说得更谨慎，而是让关键判断有可执行的依据。下一次研究应先定义估计对象和异常退出条件，再运行模型；保留不利结果、实际失败和版本差异，才能解释输出为何值得相信。仍需人工复核经济语义与研究假设，测试通过不是因果证明。

六、Git 与协作习惯

问题	我的回答
分支设置	main 之外 5 个任务分支，分别对应稳健性、Skill、Agent、论文和迭代。每个任务先建分支，完成后合并。
diff 审查	合并前审查差异和关键代码；修正课堂公式冗余项，T4 改为显式基准交互，保留异常输出。日志的尾部空格属于编译器格式，另行处理。
commit 规范	feat / fix / docs / chore / merge，说明动作与原因。代表提交：9049b5c，增加证据完整性校验并拒绝被破坏的输入。
Git 的作用	把实际尝试、拒绝的输出、修复和最终证据对应到版本；已有历史来自本次工作，不复制同学历史，不补造旧日期。

Git 历史文本快照

```
* a444c3b (HEAD -> main) merge: complete Part E iterations migration and print submission
|\
| * b2ac383 (task-e-iterate) docs: complete migration evidence and verified submission materials
| * 9049b5c fix: enforce agent evidence completeness and reject corrupted inputs
|/
* 7a656ed merge: complete Part D compiled research paper
|\
| * 833ca6d (task-d-paper) docs: write and compile Chinese paper with verified references and bounded claims
|/
* ceab66a merge: complete Part C evaluation design
|\
| * 8b216e6 (task-c-agent) feat: add theme-aware evaluation agent and initial assessment
|/
* dbe9f93 merge: complete Part B and first evidence-based iteration
|\
| * 819ad98 (task-b-skill) fix: qualify finite placebo simulation and verify controlled skill comparison
| * 4e57924 feat: add generic skill prototype with explicit variable contracts
|/
* d8ab813 merge: complete Part A with reproducible statistical evidence
|\
| * 189c364 (task-a-robustness) feat: execute DID robustness checks and resolve absorbed-control instability
| * e9d4d95 docs: preregister estimand and test-specific four-part prompts
|/
* 388432e chore: initialize independent coursework from classroom sources
```

快照保存于生成材料时；后续提交以仓库 `git log --oneline --graph --all` 为准。远程仓库由本人最后创建并推送。

附录 提交物自查清单

提交物	位置	状态
完整 Git 仓库	did-homework/.git	已完成
识别目标	output/estimand.md	已完成
Prompt	prompts/robustness/	基准+12 张
检验汇总	output/robustness_summary.md	已完成
全部结果	output/*.csv、*.png	已完成
Skill	.claude/skills/robustness-check/	已验证
Skill 对照	audit-log.md、output/skill_comparison.json	已完成
Agent	.claude/agents/eval-did-robustness.md	已完成
综合评估	output/eval_robustness_report.md	已完成
论文与 PDF	paper/main.tex、main.pdf	实际编译
AI 使用记录	audit-log.md	已完成
两轮迭代	output/iteration_reflection.md	已完成
Git 历史	output/git-history.txt	已完成
纸质材料	submission/纸质提交材料.docx 及 PDF	已生成
远程推送与链接	按 GITHUB_UPLOAD.md 操作	待本人完成

关键证据速查

复现：output/baseline_comparison.md。推断口径：diagnostics.json 及 all_results.csv。原始公式异常：output/iterations/baseline_original_script.csv。迁移：output/migration/README.md 和 negative_tests.json。文献核查：quality_reports/crossref_verified.json。

论文与纸质材料均保留合成数据边界。材料中没有虚构现实数据、参考文献、独立模型调用或 GitHub 地址；提交前需将本人真实仓库链接填入封面，确认内容后打印。